Instituto Federal de Educação, Ciência e Tecnologia de São Paulo

Câmpus Itapetininga

Tecnologia em Sistemas para Internet

Probabilidade e Estatística Aplicada

Distribuição Normal e Curva de Gauss

Análise das notas de matemática da base *Students Performance in Exams* com implementação em Python

Mariana Alice Pires Leite (3043151)

Prof. Dr. Wilton Moreira Ferraz Junior

Itapetininga

Novembro de 2026

Sumário

1 Introdução **2**

2 Parte A: pesquisa teórica **2**

2.1 Distribuição normal e Curva de Gauss 2

2.2 Função da média e do desvio-padrão 3

2.3 Regra empírica 68–95–99,7 3

2.4 Escore padronizado z 4

3 Parte B: leitura e organização dos dados **4**

3.1 O que foi feito 4

3.2 Resultado 5

4 Parte C: medidas estatísticas **5**

4.1 O que foi feito 5

4.2 Resultado 7

5 Parte D: regra 68–95–99,7 **7**

5.1 O que foi feito 7

5.2 Resultado 8

6 Parte E: escores padronizados **8**

6.1 O que foi feito 8

6.2 Resultado 9

7 Parte F: representação gráfica **9**

7.1 O que foi feito 9

7.2 Resultado 10

8 Parte G: conclusão **11**

Referências **12**

1 Introdução

Este relatório apresenta o desenvolvimento de um programa em Python que carrega dados numéricos de um arquivo CSV, calcula medidas estatísticas, constrói gráficos e avalia se a variável analisada apresenta comportamento aproximadamente compatível com uma distribuição normal.

A base utilizada foi a *Students Performance in Exams*, disponível no Kaggle no arquivo `StudentsPerformance.csv` (SPSCIENTIST, 2018). Ela possui 1.000 registros e oito colunas, com características dos estudantes e suas notas de matemática, leitura e escrita. A variável analisada foi a nota de matemática, armazenada na coluna `math score`, que contém valores inteiros entre 0 e 100.

Conforme as restrições da atividade, nenhum cálculo estatístico foi feito com bibliotecas prontas. O programa usa apenas os módulos `csv` e `math` para a leitura e os cálculos, e a biblioteca `matplotlib` (HUNTER, 2007) somente para os gráficos. Todos os resultados são obtidos a partir dos dados brutos do arquivo, sem valores inseridos manualmente.

As seções seguintes acompanham as partes da atividade. A Seção 2 traz a pesquisa teórica, as Seções 3 a 7 explicam o que o programa faz em cada etapa e os resultados obtidos, e a Seção 8 apresenta a conclusão.

2 Parte A: pesquisa teórica

2.1 Distribuição normal e Curva de Gauss

A distribuição normal é uma distribuição de probabilidade **contínua**, ou seja, a variável pode assumir qualquer valor real. Ela é conhecida como Curva de Gauss em homenagem ao matemático Carl Friedrich Gauss, que a utilizou no estudo de erros de medição. Esse modelo é importante porque muitas variáveis influenciadas por vários fatores pequenos e independentes, como alturas, erros de medida e notas de provas, costumam se distribuir de forma próxima a ele (BUSSAB; MORETTIN, 2017).

O gráfico da distribuição normal tem formato de sino e apresenta as seguintes características.

- É **simétrico** em relação à média, com a metade esquerda espelhando a metade direita.
- A **média, a mediana e a moda são iguais** e ficam no centro da curva, onde está o ponto mais alto.

- As **caudas** se aproximam do eixo horizontal sem tocá-lo, o que indica que valores muito afastados do centro são raros, mas possíveis.
- A **área total** sob a curva é igual a 1, e a área entre dois pontos corresponde à probabilidade de a variável cair nesse intervalo.

A distribuição normal é determinada por dois parâmetros, a média μ e o desvio-padrão σ, e sua função densidade é

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}}\, e^{-\frac{(x-\mu)^2}{2\sigma^2}}. \tag{1}$$

O termo $(x-\mu)^2$ no expoente negativo faz com que $f(x)$ diminua à medida que x se afasta da média, formando as caudas. O fator $\frac{1}{\sigma\sqrt{2\pi}}$ garante que a área total seja 1. Essa foi a fórmula usada pelo programa para desenhar a curva teórica sobre o histograma.

2.2 Função da média e do desvio-padrão

A **média** μ define o **centro** da distribuição. Aumentar ou diminuir a média desloca a curva inteira para a direita ou para a esquerda, sem mudar seu formato.

O **desvio-padrão** σ define a **dispersão**, ou seja, o quanto os valores se espalham em torno da média. Com σ pequeno a curva fica alta e estreita, e com σ grande ela fica baixa e larga.

Como os dados deste trabalho são uma amostra, a média é estimada por $\bar{x}$ e o desvio-padrão por s, o desvio-padrão amostral.

2.3 Regra empírica 68–95–99,7

Em dados normalmente distribuídos, a proporção de valores próximos da média é sempre a mesma, quaisquer que sejam μ e σ. Essa propriedade é chamada de regra empírica e afirma que aproximadamente

$$\begin{aligned} 68\% \text{ dos valores estão entre } \mu-\sigma \text{ e } \mu+\sigma,\\ 95\% \text{ dos valores estão entre } \mu-2\sigma \text{ e } \mu+2\sigma,\\ 99{,}7\% \text{ dos valores estão entre } \mu-3\sigma \text{ e } \mu+3\sigma. \end{aligned}$$

Assim, contar quantos dados caem em cada intervalo e comparar com esses percentuais é uma forma simples de avaliar se os dados se comportam de modo semelhante a uma distribuição normal.

2.4 Escore padronizado z

O escore z indica quantos desvios-padrão um valor está acima ou abaixo da média e é calculado por

$$z = \frac{x - \mu}{\sigma}. \tag{2}$$

Um valor $z = 0$ é igual à média, um z positivo está acima da média e um z negativo está abaixo. Por exemplo, $z = -2$ indica um valor dois desvios-padrão abaixo da média. Pela regra empírica, valores com $|z| > 3$ aparecem em apenas cerca de 0,3% dos casos em dados normais, por isso são considerados **possíveis valores atípicos**.

3 Parte B: leitura e organização dos dados

3.1 O que foi feito

A função `carregar_notas` abre o arquivo `StudentsPerformance.csv` com o módulo `csv` e usa a classe `csv.DictReader`. Essa classe lê a primeira linha como cabeçalho e transforma cada linha seguinte em um dicionário, de modo que a nota de cada estudante é acessada diretamente pelo nome da coluna, `registro["math score"]`.

Para cada registro, o programa faz três verificações antes de aceitar a nota.

1. Se o valor está **ausente**, isto é, vazio.
2. Se o valor pode ser **convertido para inteiro** com `int()`. Caso não possa, é considerado inválido.
3. Se a nota está dentro do **intervalo válido** de 0 a 100.

As notas aprovadas são armazenadas em uma lista, e os problemas encontrados são guardados com o número da linha do arquivo, para que possam ser informados ao usuário. O trecho a seguir mostra o núcleo dessa leitura.

```
leitor = csv.DictReader(arquivo)
for numero_linha, registro in enumerate(leitor, start=2):
    valor = registro.get("math score")
    if valor is None or valor.strip() == "":
        problemas.append((numero_linha, "valor ausente"))
        continue
    try:
        nota = int(valor.strip())
    except ValueError:
        problemas.append((numero_linha, "valor inválido"))
        continue
    if 0 <= nota <= 100:
        notas.append(nota)
```

3.2 Resultado

O programa leu **1.000 registros** e converteu todas as 1.000 notas de matemática para inteiros. **Não foram encontrados valores ausentes ou inválidos**, então todas as análises seguintes usam $n = 1000$ notas.

4 Parte C: medidas estatísticas

4.1 O que foi feito

Cada medida foi implementada em uma função própria, usando apenas laços, operações aritméticas e a função `math.sqrt` para a raiz quadrada. A Tabela 1 resume como cada medida foi calculada.

Tabela 1: Medidas calculadas e forma de cálculo.

Medida	**Como foi calculada**
Quantidade, menor e maior nota	Tamanho da lista e primeiro e último elementos da lista ordenada
Amplitude total	$A = x_{\max} - x_{\min}$
Média aritmética	$\bar{x} = \dfrac{1}{n}\sum_{i=1}^{n} x_i$
Mediana	Valor central da lista ordenada. Como n é par, é a média dos elementos nas posições $\frac{n}{2}$ e $\frac{n}{2}+1$
Moda ou modas	Dicionário com a frequência de cada nota, retornando todas as notas que empatam na maior frequência
Variância amostral	$s^2 = \dfrac{\sum(x_i - \bar{x})^2}{n-1}$
Desvio-padrão amostral	$s = \sqrt{\dfrac{\sum(x_i - \bar{x})^2}{n-1}}$
Coeficiente de assimetria	$g = \dfrac{n}{(n-1)(n-2)} \sum \left(\dfrac{x_i - \bar{x}}{s}\right)^3$

Na variância e no desvio-padrão amostrais, divide-se por $n-1$ em vez de n. Essa correção compensa o fato de a média ter sido calculada com os próprios dados, o que tornaria a dispersão levemente subestimada.

O coeficiente de assimetria mede o quanto a distribuição se afasta da simetria. Como os desvios são elevados ao cubo, eles mantêm o sinal. Um valor negativo indica cauda mais longa à esquerda, um valor positivo indica cauda mais longa à direita, e um valor próximo de zero indica simetria. Foi adotada a interpretação de que $|g| < 0{,}1$ é aproximadamente simétrico, $0{,}1 \leq |g| < 0{,}5$ é assimetria leve, $0{,}5 \leq |g| < 1$ é moderada e $|g| \geq 1$ é forte.

4.2 Resultado

Tabela 2: Medidas estatísticas das notas de matemática.

Medida	**Valor**
Quantidade de dados (n)	1000
Menor nota	0
Maior nota	100
Amplitude total	100
Média aritmética ($\bar{x}$)	66,0890
Mediana	66
Moda	65 (36 ocorrências)
Variância amostral (s^2)	229,9190
Desvio-padrão amostral (s)	15,1631
Coeficiente de assimetria (g)	−0,2789

Exemplo numérico (mediana e desvio-padrão)

Como $n = 1000$ é par, a mediana é a média das notas nas posições 500 e 501 da lista ordenada. As duas valem 66, então a mediana é $\frac{66+66}{2} = 66$.
A variância obtida foi $s^2 = 229{,}9190$, expressa em pontos ao quadrado. Tirando a raiz, volta-se à unidade das notas, $s = \sqrt{229{,}9190} \approx 15{,}16$ pontos. Isso significa que, em geral, as notas se afastam cerca de 15 pontos da média.

A média (66,09), a mediana (66) e a moda (65) ficaram muito próximas, como se espera em uma distribuição normal. O coeficiente de assimetria $g = -0{,}2789$ indica **leve assimetria negativa**, ou seja, a cauda das notas baixas é um pouco mais longa que a das notas altas.

5 Parte D: regra 68–95–99,7

5.1 O que foi feito

A função `regra_empirica` calcula, para $k = 1$, 2 e 3, os limites $\bar{x} - k\,s$ e $\bar{x} + k\,s$. Em seguida, percorre a lista de notas contando quantas estão dentro de cada intervalo, e calcula o percentual dividindo essa contagem por n e multiplicando por 100.

5.2 Resultado

Tabela 3: Percentuais observados comparados à regra empírica.

Intervalo	Limites	Qtd.	Observado	Esperado	Diferença
$\bar{x} \pm 1s$	[50,93; 81,25]	696	69,60%	68%	+1,60 p.p.
$\bar{x} \pm 2s$	[35,76; 96,42]	954	95,40%	95%	+0,40 p.p.
$\bar{x} \pm 3s$	[20,60; 111,58]	996	99,60%	99,7%	−0,10 p.p.

Exemplo numérico (primeiro intervalo)

Com $\bar{x} = 66{,}0890$ e $s = 15{,}1631$, os limites de $\bar{x} \pm 1s$ são $66{,}0890 - 15{,}1631 = 50{,}93$ e $66{,}0890 + 15{,}1631 = 81{,}25$. Como as notas são inteiras, esse intervalo vai da nota 51 à nota 81. Na base há 696 notas nessa faixa, o que corresponde a $\frac{696}{1000} \times 100 = 69{,}60\%$.

Os três percentuais ficaram muito próximos dos teóricos, com diferença máxima de 1,6 ponto percentual. O intervalo de um desvio-padrão ficou um pouco acima do esperado, o que mostra uma concentração ligeiramente maior de notas em torno da média. Também é interessante notar que o limite superior do terceiro intervalo, 111,58, passa da nota máxima possível, que é 100.

6 Parte E: escores padronizados

6.1 O que foi feito

A função `escore_z` aplica a Equação (2) usando $\bar{x}$ e s no lugar de μ e σ. Ela foi aplicada à menor nota, à maior nota e às notas 50, 75 e 90. Cada resultado foi classificado como possível valor atípico quando $|z| > 3$. Além disso, o programa percorreu toda a base para listar todas as notas que atendem a esse critério.

6.2 Resultado

Tabela 4: Escores z das notas solicitadas.

Caso	Nota	Escore z	Classificação
Menor nota	0	−4,3585	Possível valor atípico
Maior nota	100	2,2364	Dentro do esperado
Nota 50	50	−1,0611	Dentro do esperado
Nota 75	75	0,5877	Dentro do esperado
Nota 90	90	1,5769	Dentro do esperado

Exemplo numérico (nota 75)

$$z = \frac{75 - 66{,}0890}{15{,}1631} = \frac{8{,}9110}{15{,}1631} \approx 0{,}5877.$$

O valor positivo mostra que a nota 75 está acima da média, a uma distância de pouco mais de meio desvio-padrão.

Apenas a menor nota, 0, foi classificada como possível valor atípico entre os casos pedidos, pois está mais de quatro desvios-padrão abaixo da média. Ao analisar toda a base, o programa encontrou **quatro notas com** $|z| > 3$, que são 0, 8, 18 e 19. Elas representam 0,4% dos dados e estão todas na cauda inferior, o que é coerente com a leve assimetria negativa.

7 Parte F: representação gráfica

7.1 O que foi feito

A função `gerar_histograma` usa o `matplotlib` para construir o histograma das notas com classes de largura 5, de 0 a 100. Foi usada a opção `density=True`, que transforma a altura das barras em densidade e faz a área total do histograma valer 1. Isso permite comparar o histograma diretamente com a curva normal, cuja área também vale 1.

A curva normal teórica foi desenhada calculando a Equação (1) em 1.001 pontos entre 0 e 100, com a média e o desvio-padrão obtidos na Parte C. Foram adicionadas uma linha vertical na média e duas linhas tracejadas em $\bar{x} - s$ e $\bar{x} + s$. O resultado foi salvo como `histograma_curva_normal.png`. Também foi gerado o gráfico de caixa opcional, salvo como `boxplot.png`.

7.2 Resultado

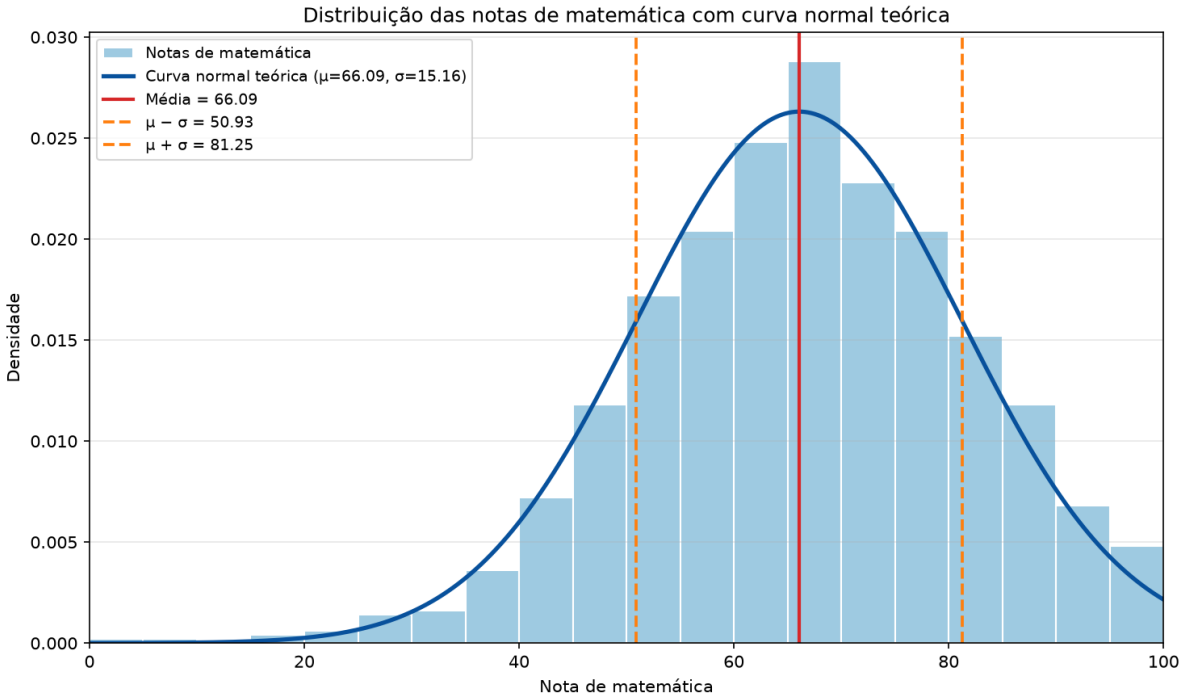


Figura 1: Histograma das notas de matemática com a curva normal teórica. A linha vermelha marca a média e as tracejadas marcam $\bar{x} \pm s$.

O histograma tem formato de sino bem definido, com as barras mais altas perto da média e diminuindo em direção às extremidades. A curva teórica acompanha de perto o contorno das barras. As principais diferenças são a classe de 65 a 70, que fica acima da curva, e a cauda esquerda, que se estende até a nota 0, enquanto a direita termina no limite de 100.

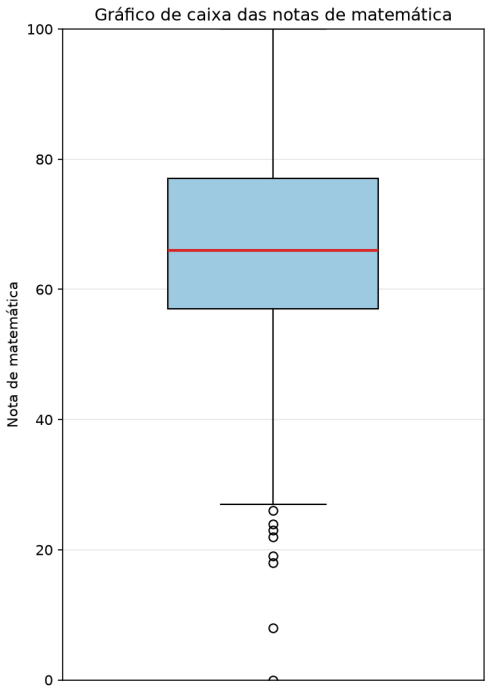


Figura 2: Gráfico de caixa das notas de matemática.

No gráfico de caixa, a mediana está praticamente no centro da caixa, indicando que a parte central dos dados é quase simétrica. Os pontos isolados aparecem só abaixo da caixa, confirmando que os valores extremos estão entre as notas baixas.

8 Parte G: conclusão

O histograma apresenta aproximadamente o formato de sino? Sim. O histograma tem um pico central próximo da média e frequências que diminuem gradualmente nas duas direções, e a curva normal teórica acompanha bem o contorno das barras.

Média e mediana apresentam valores próximos? Sim. A média foi 66,089 e a mediana foi 66, uma diferença de apenas 0,089 ponto. A moda, 65, também está muito próxima, o que indica uma distribuição quase simétrica.

Os percentuais observados são próximos da regra 68–95–99,7? Sim. Os valores observados foram 69,60%, 95,40% e 99,60%, contra 68%, 95% e 99,7% esperados. A maior diferença foi de 1,6 ponto percentual, no intervalo de um desvio-padrão.

A distribuição apresenta assimetria? Sim, mas leve. O coeficiente de assimetria foi $-0{,}2789$, indicando assimetria negativa leve, causada por algumas notas muito baixas que

alongam a cauda esquerda.

Existem valores atípicos? Sim. Quatro notas apresentaram $|z| > 3$, que são 0, 8, 18 e 19. O critério indica apenas possíveis valores atípicos. Essas notas não são necessariamente erros, pois podem representar estudantes que realmente tiveram desempenho muito baixo, e por isso foram mantidas na análise.

É adequado afirmar que os dados seguem perfeitamente uma distribuição normal? Não. A distribuição normal é contínua, simétrica e admite qualquer valor real, enquanto as notas são inteiras, limitadas entre 0 e 100 e apresentam leve assimetria negativa. O próprio limite de 111,58 do intervalo de três desvios-padrão mostra que o modelo admite valores impossíveis para uma nota. Além disso, as técnicas usadas neste trabalho são descritivas e visuais, e não testes formais de normalidade.

Qual seria uma conclusão mais cuidadosa sobre a distribuição das notas? As notas de matemática apresentam **comportamento aproximadamente normal**. O histograma tem formato de sino, as medidas de tendência central são praticamente iguais e os percentuais da regra empírica estão muito próximos dos teóricos. Por outro lado, há uma leve assimetria negativa e alguns valores atípicos na cauda inferior. Portanto, a distribuição normal é um modelo adequado para descrever de forma geral o desempenho dos estudantes, desde que seja entendida como uma aproximação, e não como uma descrição exata dos dados.

Referências

BUSSAB, W. O.; MORETTIN, P. A. **Estatística básica**. 9. ed. São Paulo: Saraiva, 2017.

HUNTER, J. D. Matplotlib: a 2D graphics environment. **Computing in Science & Engineering**, v. 9, n. 3, p. 90-95, 2007. DOI: `https://doi.org/10.1109/MCSE.2007.55`.

SPSCIENTIST. **Students performance in exams**. [*S. l.*]: Kaggle, 2018. Disponível em: `https://www.kaggle.com/datasets/spscientist/students-performance-in-exams`. Acesso em: 10 nov. 2026.